

# Modelo con k regresores

## Contents

<b>1</b>	<b>Modelo y su estimación</b>	<b>1</b>
<b>2</b>	<b>Residuos</b>	<b>2</b>
2.1	Matriz H . . . . .	2
2.2	Ortogonalidad de residuos y regresores . . . . .	3
<b>3</b>	<b>El modelo en diferencias a la media</b>	<b>3</b>
3.1	Modelo . . . . .	3
3.2	Estimación del modelo utilizando matrices de covarianzas . . . . .	4
3.3	Residuos . . . . .	5
3.4	Aplicación a los datos . . . . .	5

## 1 Modelo y su estimación

Supongamos que se tiene el siguiente modelo de regresión lineal:

$$y_i = b_0 + b_1x_{1i} + b_2x_{2i} + \cdots + b_kx_{ki} + e_i, \quad i = 1, 2, \dots, n$$

- El término  $y_i$  se conoce como *variable respuesta*, y las  $x$  se conocen como *regresores*.
- El término  $e_i$  representa el error del modelo.

La ecuación del modelo se puede escribir en notación matricial:

$$i = 1 \Rightarrow y_1 = b_0 + b_1x_{11} + b_2x_{21} + \cdots + b_kx_{k1} + e_1$$

$$i = 2 \Rightarrow y_2 = b_0 + b_1x_{12} + b_2x_{22} + \cdots + b_kx_{k2} + e_2$$

...

$$i = n \Rightarrow y_n = b_0 + b_1x_{1n} + b_2x_{2n} + \cdots + b_kx_{kn} + e_n$$

Agrupando:

$$\begin{bmatrix} y_1 \\ y_2 \\ \dots \\ y_n \end{bmatrix} = \begin{bmatrix} 1 & x_{11} & x_{21} & \cdots & x_{k1} \\ 1 & x_{12} & x_{22} & \cdots & x_{k2} \\ \dots & \dots & \dots & \dots & \dots \\ 1 & x_{1n} & x_{2n} & \cdots & x_{kn} \end{bmatrix} \begin{bmatrix} b_0 \\ b_1 \\ b_2 \\ \dots \\ b_k \end{bmatrix} + \begin{bmatrix} e_1 \\ e_2 \\ \dots \\ e_n \end{bmatrix}$$

Finalmente:

$$y = XB + e$$

Esta ecuación es válida para cualquier número de regresores y cualquier número de observaciones.

En este caso, el vector de parámetros estimados es:

$$B = \begin{bmatrix} b_0 \\ b_1 \\ b_2 \\ \vdots \\ b_k \end{bmatrix}$$

Los residuos, igual que en los apartados precedentes se calculan

$$e = y - \hat{y} = y - XB$$

La suma de residuos al cuadrado será:

$$RSS(B) = \sum e_i^2 = e^T e = y^T y - y^T XB - B^T X^T y + B^T X^T XB$$

El método de mínimos cuadrados consiste en minimizar dicha suma, con lo que se obtiene:

$$B = (X^T X)^{-1} X^T y$$

Todo lo presentado en los apartados precedentes es aplicable en este caso también.

## 2 Residuos

La ecuación del modelo se puede expresar como

$$y = XB + e = \hat{y} + e$$

Es decir, los datos  $y$  se descomponen en parte perteneciente a la recta ( $\hat{y} = XB$ ) y parte no perteneciente a la recta o residuos ( $e$ ). Ambas se pueden calcular ahora ya que se conoce  $B$ .

### 2.1 Matriz H

Se define la matriz  $H$  como:

$$\hat{y} = XB = X(X^T X)^{-1} X^T y = Hy$$

La matriz  $H = X(X^T X)^{-1} X^T$  se denomina en inglés *hat matrix*. Es sencillo comprobar que la matriz  $H$  es simétrica ( $H^T = H$ ) e idempotente ( $H \cdot H = H$ ).

Los residuos se pueden expresar en función de dicha matriz como:

$$e = y - \hat{y} = (I - H)y$$

Se suele utilizar para derivar resultados teóricos. Por ejemplo, utilizando esta matriz se puede demostrar la siguiente propiedad para la suma de los residuos al cuadrado:

$$\begin{aligned}\sum e_i^2 &= e^T e = (y - Hy)^T (y - Hy) = y^T y - y^T Hy - y^T H^T y + y^T H^T Hy = y^T y - y^T H^T y \\ &= y^T y - (Hy)^T y = y^T y - (XB)^T y = y^T y - B^T (X^T y)\end{aligned}$$

Finalmente

$$\sum e_i^2 = y^T y - B^T (X^T y)$$

## 2.2 Ortogonalidad de residuos y regresores

Otra propiedad importante de los residuos es que  $X^T e = 0$ . Efectivamente, sustituyendo el valor de  $B$  en la ecuación del modelo

$$y = XB + e = X(X^T X)^{-1} X^T y + e$$

Multiplicando por la izquierda por  $X^T$  se obtiene

$$X^T y = (X^T X)(X^T X)^{-1} X^T y + X^T e \Rightarrow X^T y = X^T y + X^T e \Rightarrow X^T e = 0$$

Si escribimos dicha propiedad en función de las componentes de las matrices:

$$X^T e = \begin{bmatrix} 1 & x_{11} & x_{21} & \cdots & x_{k1} \\ 1 & x_{12} & x_{22} & \cdots & x_{k2} \\ \cdots & \cdots & \cdots & \cdots & \cdots \\ 1 & x_{1n} & x_{2n} & \cdots & x_{kn} \end{bmatrix}^T \begin{bmatrix} e_1 \\ e_2 \\ \cdots \\ e_n \end{bmatrix} = \begin{bmatrix} \sum e_i \\ \sum x_{1i} e_i \\ \cdots \\ \sum x_{ki} e_i \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ \cdots \\ 0 \end{bmatrix}$$

Este producto equivale a las siguientes ecuaciones:

$$\sum e_i = 0, \sum x_{1i} e_i = 0, \sum x_{2i} e_i = 0, \cdots, \sum x_{ki} e_i = 0$$

La primera ecuación indica que los residuos siempre suman cero. Las siguientes ecuaciones indican que el vector residuos es ortogonal a las columnas de la matriz  $X$  (consideradas estas columnas como vectores). Por tanto es ortogonal al espacio vectorial generado por dichos vectores.

## 3 El modelo en diferencias a la media

### 3.1 Modelo

Dada la ecuación del modelo

$$y_i = b_0 + b_1 x_{1i} + b_2 x_{2i} + \cdots + b_k x_{ki} + e_i, \quad i = 1, 2, \cdots, n$$

Si sumamos en ambos miembros desde 1 hasta  $n$

$$\sum y_i = \sum b_0 + b_1 \sum x_{1i} + b_2 \sum x_{2i} + \cdots + b_k \sum x_{ki} + \sum e_i$$

Teniendo en cuenta que los residuos suman cero

$$\sum y_i = nb_0 + b_1 \sum x_{1i} + b_2 \sum x_{2i} + \cdots + b_k \sum x_{ki}$$

Y dividiendo entre  $n$

$$\bar{y} = b_0 + b_1 \bar{x}_1 + b_2 \bar{x}_2 + \cdots + b_k \bar{x}_k$$

Si a la ecuación del modelo le restamos esta última ecuación se obtiene:

$$y_i - \bar{y} = b_1(x_{1i} - \bar{x}_1) + b_2(x_{2i} - \bar{x}_2) + \cdots + b_k(x_{ki} - \bar{x}_k) + e_i, \quad i = 1, 2, \dots, n$$

Estas  $n$  ecuaciones se pueden expresar en forma matricial de la misma forma que hicimos antes, obteniendo:

$$\begin{bmatrix} y_1 - \bar{y} \\ y_2 - \bar{y} \\ \vdots \\ y_n - \bar{y} \end{bmatrix} = \begin{bmatrix} x_{11} - \bar{x}_1 & x_{21} - \bar{x}_2 & \cdots & x_{k1} - \bar{x}_k \\ x_{12} - \bar{x}_1 & x_{22} - \bar{x}_2 & \cdots & x_{k2} - \bar{x}_k \\ \vdots & \vdots & \ddots & \vdots \\ x_{1n} - \bar{x}_1 & x_{2n} - \bar{x}_2 & \cdots & x_{kn} - \bar{x}_k \end{bmatrix} \begin{bmatrix} b_1 \\ b_2 \\ \vdots \\ b_k \end{bmatrix} + \begin{bmatrix} e_1 \\ e_2 \\ \vdots \\ e_n \end{bmatrix}$$

Que en este caso se expresa como

$$y_a = X_a B_a + e$$

donde  $B_a$  es el vector de coeficientes del modelo excepto  $b_0$ .

### 3.2 Estimación del modelo utilizando matrices de covarianzas

Se puede demostrar que  $X_a^T e = 0$ :

$$X_a^T e = \begin{bmatrix} x_{11} - \bar{x}_1 & x_{21} - \bar{x}_2 & \cdots & x_{k1} - \bar{x}_k \\ x_{12} - \bar{x}_1 & x_{22} - \bar{x}_2 & \cdots & x_{k2} - \bar{x}_k \\ \vdots & \vdots & \ddots & \vdots \\ x_{1n} - \bar{x}_1 & x_{2n} - \bar{x}_2 & \cdots & x_{kn} - \bar{x}_k \end{bmatrix}^T \begin{bmatrix} e_1 \\ e_2 \\ \vdots \\ e_n \end{bmatrix} = \begin{bmatrix} \sum (x_{1i} - \bar{x}_1)e_i \\ \sum (x_{2i} - \bar{x}_2)e_i \\ \vdots \\ \sum (x_{ki} - \bar{x}_k)e_i \end{bmatrix} = \begin{bmatrix} \sum x_{1i}e_i - \bar{x}_1 \sum e_i \\ \sum x_{2i}e_i - \bar{x}_2 \sum e_i \\ \vdots \\ \sum x_{ki}e_i - \bar{x}_k \sum e_i \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ \vdots \\ 0 \end{bmatrix}$$

Por tanto, partiendo de la ecuación en diferencias a la media:

$$y_a = X_a B_a + e$$

y multiplicando ambos miembros por  $X_a^T$ :

$$X_a^T y_a = X_a^T X_a B_a + X_a^T e \Rightarrow B_a = (X_a^T X_a)^{-1} (X_a^T Y_a) = \left( \frac{1}{n-1} X_a^T X_a \right)^{-1} \left( \frac{1}{n-1} X_a^T Y_a \right)$$

$$B_a = S_{XX}^{-1} S_{Xy}$$

donde  $S_{Xy}$  es la matriz de covarianzas de  $X$  e  $y$ , y  $S_{XX}$  es la matriz de covarianzas de  $X$ :

$$S_{Xy} = \frac{1}{n-1} X_a^T y_a = \begin{bmatrix} S_{1y} \\ S_{2y} \\ \vdots \\ S_{ky} \end{bmatrix}$$

$$S_{XX} = \frac{1}{n-1} X_a^T X_a = \begin{bmatrix} S_{11} & S_{21} & \cdots & S_{k1} \\ S_{12} & S_{22} & \cdots & S_{k2} \\ \cdots & \cdots & \cdots & \cdots \\ S_{1k} & S_{2k} & \cdots & S_{kk} \end{bmatrix}$$

donde  $S_{ij}$  representa la covarianza entre  $x_i$  e  $x_j$ , y  $S_{iy}$  representa la covarianza entre  $x_i$  e  $y$  (ver Apendice).

Las ecuaciones derivadas en este apartado constituyen una alternativa para la estimación de los coeficientes del modelo de regresión lineal.

A modo de resumen:

- Las matrices  $X$  e  $y$  son matrices de **datos**. Con ellas se pueden estimar los parámetros del modelo haciendo  $B = (X^T X)^{-1} X^T y$ .
- Las matrices  $S_{Xy}$  y  $S_{XX}$  son matrices de **covarianzas**. Con ellas se pueden estimar los parámetros del modelo haciendo  $B_a = S_{XX}^{-1} S_{Xy}$ .

### 3.3 Residuos

Los residuos en este modelo se definen como

$$e = y_a - X_a B_a$$

Se ha demostrado que  $X_a^T e = 0$ . Por último vamos a demostrar otra propiedad análoga a la obtenida con el modelo con matrices de datos:

$$\begin{aligned} \sum e_i^2 &= e^T e = (y_a - X_a B_a)^T (y_a - X_a B_a) = y_a^T y_a - y_a^T X_a B_a - B_a^T X_a^T y_a - B_a^T X_a^T X_a B_a \\ &= (n-1)s_y^2 - (n-1)S_{Xy}^T B_a - (n-1)B_a^T S_{Xy} + (n-1)(S_{XX}^{-1} S_{Xy})^T S_{XX} B_a \end{aligned}$$

Finalmente:

$$\sum e_i^2 = (n-1)s_y^2 - (n-1)B_a^T S_{Xy}$$

### 3.4 Aplicación a los datos

Para comprobar su funcionamiento, vamos a aplicarlo al caso de dos regresores:

```
d = read.csv("datos/kidiq.csv")

# en primer lugar vamos a calcular las matrices de covarianzas con la función de R cov()
(S = cov(d))

##          kid_score  mom_hs  mom_iq  mom_work  mom_age
## kid_score 416.596205 1.9864731 137.244279 2.1105672 5.0719235
## mom_hs    1.986473 0.1687562  1.742053 0.1232267 0.2380403
## mom_iq    137.244279 1.7420527 225.000000 2.0344125 3.7116099
## mom_work   2.110567 0.1232267  2.034413 1.3956908 0.4326955
## mom_age    5.071923 0.2380403  3.711610 0.4326955 7.2957770

(Sxx = S[c(3,5),c(3,5)])
```

```
##          mom_iq mom_age
## mom_iq  225.00000 3.711610
## mom_age   3.71161 7.295777
```

```
(Sxy = S[c(3,5),1] )
```

```
##          mom_iq mom_age
## 137.244279    5.071923
```

```
(Ba = solve(Sxx) %*% Sxy)
```

```
##          [,1]
## mom_iq  0.6035720
## mom_age  0.3881286
```

Vamos a comprobar que las matrices de covarianzas se pueden calcular a partir de  $X_a$  e  $Y_a$ :

```
ya = matrix(d$kid_score - mean(d$kid_score), ncol = 1)
Xa = cbind(d$mom_iq - mean(d$mom_iq), d$mom_age - mean(d$mom_age)) # sin columna de unos!!!!
```

```
n = nrow(d)
1/(n-1) * t(Xa) %*% Xa
```

```
##          [,1] [,2]
## [1,] 225.00000 3.711610
## [2,]   3.71161 7.295777
```

```
1/(n-1) * t(Xa) %*% ya
```

```
##          [,1]
## [1,] 137.244279
## [2,]   5.071923
```

Falta calcular  $b_0$ . Utilizamos la fórmula

$$b_0 = \bar{y} - (b_1\bar{x}_1 + b_2\bar{x}_2 + \dots + b_k\bar{x}_k)$$

```
( b0 = mean(d$kid_score) - colMeans(d[,c(3,5)]) %*% Ba )
```

```
##          [,1]
## [1,] 17.59625
```

Por último, para la suma de los residuos al cuadrado:

```
# varianza de y
(sy2 = S[1,1] )
```

```
## [1] 416.5962
```

```
(RSS = (n-1)*sy2 - (n-1)*t(Ba) %*% Sxy)
```

```
##          [,1]
## [1,] 143665.4
```