

# Estimadores y su distribución. Inferencia

## Contents

<b>1 Inferencia de parámetros individuales</b>	<b>1</b>
1.1 Distribución asintótica de los estimadores . . . . .	1
1.2 Contrastes de hipótesis individuales . . . . .	2
1.3 Intervalos de confianza . . . . .	4

## 1 Inferencia de parámetros individuales

### 1.1 Distribución asintótica de los estimadores

Para muestras grandes, los estimadores de máxima verosimilitud tienen distribución asintótica normal. En concreto, se tiene que

$$\hat{\beta} \sim N(\beta, I(\hat{\beta}))$$

donde  $I(\beta)$  se denomina Matriz de Información de Fisher observada:

$$I(\beta) = -H_{\log L}^{-1}(\beta)$$

es decir, la inversa del hessiano de la función de verosimilitud (con signo negativo):

$$H_{\log L}(\beta) = -X^T W X$$

En el caso de la propiedad anterior, la matriz  $I(\beta)$  está evaluada en el valor que maximiza la verosimilitud,  $I(\hat{\beta})$ .

Por tanto, cada estimador de manera individual se distribuye como:

$$\hat{\beta}_j \sim N(\beta_j, \text{Var}(\hat{\beta}_j))$$

donde

$$\text{Var}(\hat{\beta}_j) = I_{(j+1, j+1)}(\hat{\beta}), \quad j = 0, 1, \dots, k$$

es decir, los elementos de la diagonal de la matriz  $I(\hat{\beta})$ . Al igual que en regresión lineal, el *standard error* de los estimadores es:

$$se(\hat{\beta}_j) = \sqrt{\text{Var}(\hat{\beta}_j)}$$

## 1.2 Contrastes de hipótesis individuales

Para resolver contrastes del tipo:

$$H_0 : \beta_j = 0 H_1 : \beta_j \neq 0$$

se utiliza la distribución asintótica mostrada anteriormente:

$$\frac{\hat{\beta}_j - \beta_j}{se(\hat{\beta}_j)} \sim N(0, 1)$$

Por tanto, si la hipótesis nula es cierta se tiene:

$$\frac{\hat{\beta}_j}{se(\hat{\beta}_j)} \sim N(0, 1)$$

A este método (contraste de hipótesis utilizando la distribución asintótica de los estimadores) se lo conoce como método de Wald, o estadístico de Wald.

Con R:

```
d = read.csv("datos/MichelinNY.csv")
str(d)

## 'data.frame':    164 obs. of  6 variables:
## $ InMichelin      : int  0 0 0 1 0 0 1 1 1 0 ...
## $ Restaurant.Name: chr  "14 Wall Street" "212" "26 Seats" "44" ...
## $ Food            : int  19 17 23 19 23 18 24 23 27 20 ...
## $ Decor           : int  20 17 17 23 12 17 21 22 27 17 ...
## $ Service         : int  19 16 21 16 19 17 22 21 27 19 ...
## $ Price           : int  50 43 35 52 24 36 51 61 179 42 ...

#d$InMichelin = factor(d$InMichelin)
```

Estimamos los parámetros del modelo (se van a utilizar las funciones de R del archivo logit\_funciones.R):

```
# cargamos las funciones que vamos a utilizar
source("funciones/logit_funciones.R")

# punto de partida
m = lm(InMichelin ~ Food + Decor + Service + Price, data = d)
beta_i = coef(m)

# matriz X
X = cbind(rep(1,nrow(d)), d[,3:6])

# estimacion con el algoritmo optim
mle = optim(par = beta_i, fn = logit_logL_optim, gr = NULL,
  y = d$InMichelin, X = X,
  method = "BFGS", hessian = F,
  control = list(trace = 1, REPORT = 1, maxit = 200))

## initial value 108.793234
## iter 2 value 108.179208
## iter 3 value 95.583943
## iter 4 value 94.546080
```

```
## iter    5 value 93.925129
## iter    6 value 76.862843
## iter    7 value 74.881601
## iter    8 value 74.297605
## iter    9 value 74.231461
## iter   10 value 74.210848
## iter   11 value 74.202494
## iter   12 value 74.199408
## iter   13 value 74.199353
## iter   14 value 74.199254
## iter   15 value 74.199238
## iter   16 value 74.199235
## iter   17 value 74.198614
## iter   18 value 74.198479
## iter   19 value 74.198474
## iter   19 value 74.198474
## iter   19 value 74.198474
## final   value 74.198474
## converged
```

```
(beta_e = mle$par)
```

```
## (Intercept)      Food      Decor      Service      Price
## -11.19660070  0.40483799  0.09992470 -0.19249028  0.09175322
```

```
# matriz de información de Fisher
```

```
I = -solve(logit_hess(beta_e,X))
```

```
# standard error de los parámetros estimados
```

```
(beta_se = sqrt(diag(I)))
```

```
## rep(1, nrow(d))      Food      Decor      Service      Price
##      2.30897047      0.13146216      0.08919429      0.12357290      0.03175475
```

```
# valor del estadístico del contraste
```

```
(z = beta_e/beta_se)
```

```
## (Intercept)      Food      Decor      Service      Price
##  -4.849174      3.079502      1.120304      -1.557706      2.889433
```

```
# pvalores
```

```
2*(1 - pnorm(abs(z)))
```

```
## (Intercept)      Food      Decor      Service      Price
## 1.239763e-06 2.073469e-03 2.625843e-01 1.193029e-01 3.859378e-03
```

Esta información se obtiene cuando utilizamos la función glm():

```
m1 = glm(InMichelin ~ Food + Decor + Service + Price, data = d, family = binomial)
summary(m1)
```

```
##
```

```
## Call:
```

```
## glm(formula = InMichelin ~ Food + Decor + Service + Price, family = binomial,
```

```
##      data = d)
```

```
##
```

```
## Coefficients:
```

```
##      Estimate Std. Error z value Pr(>|z|)
```

```
## (Intercept) -11.19745      2.30896  -4.850 1.24e-06 ***
```

```
## Food          0.40485    0.13146    3.080    0.00207 **
## Decor          0.09997    0.08919    1.121    0.26235
## Service       -0.19242    0.12357   -1.557    0.11942
## Price          0.09172    0.03175    2.889    0.00387 **
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
##      Null deviance: 225.79  on 163  degrees of freedom
## Residual deviance: 148.40  on 159  degrees of freedom
## AIC: 158.4
##
## Number of Fisher Scoring iterations: 6
```

### 1.3 Intervalos de confianza

Partimos de nuevo del estadístico de Wald:

$$\frac{\hat{\beta}_j - \beta_j}{se(\hat{\beta}_j)} \sim N(0, 1)$$

Por tanto, el intervalo será:

$$\hat{\beta}_j - z_{\alpha/2} se(\hat{\beta}_j) \leq \beta_j \leq \hat{\beta}_j + z_{\alpha/2} se(\hat{\beta}_j)$$

```
alfa = 0.05
data.frame(LI = beta_e - qnorm(1-alfa/2)*beta_se,
           LS = beta_e + qnorm(1-alfa/2)*beta_se)
```

```
##              LI              LS
## (Intercept) -15.72209967 -6.67110173
## Food         0.14717690  0.66249909
## Decor        -0.07489290  0.27474231
## Service      -0.43468871  0.04970816
## Price         0.02951504  0.15399139
```

```
confint(m1, level = 1-alfa)
```

```
## Waiting for profiling to be done...
```

```
##              2.5 %          97.5 %
## (Intercept) -16.05404706 -6.93894624
## Food         0.14737740  0.66963794
## Decor        -0.07378966  0.27855161
## Service      -0.44107191  0.04758419
## Price         0.03153229  0.15709677
```